TP 3 - SIMULACIÓN DE UN MODELO MM1 E INVENTARIO

Dafne Müller
Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
dafnemuller1@gmail.com

Ángela Periolo
Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
angieperiolo@hotmail.com

Agustina Chamas
Ingeniería en Sistemas de Información
Universidad Tecnológica Nacional - FRRO
Zeballos 1341, S2000, Argentina
aguschamas1610@gmail.com

5 de julio de 2026

ABSTRACT

En este trabajo se desarrolla la simulación por eventos discretos de un sistema de colas M/M/1 y de un modelo de inventario. Para ambos casos se obtienen las principales medidas de rendimiento mediante implementaciones en Python y AnyLogic, las cuales se comparan con los resultados teóricos correspondientes. Además, se realizan múltiples corridas de simulación y se analiza el comportamiento de cada modelo frente a diferentes configuraciones de parámetros.

***K*eywords** Simulación · Modelo MM1 · Inventario · Trabajo práctico

1. Introducción

La simulación por eventos discretos constituye una herramienta muy utilizada para el análisis de sistemas dinámicos cuyo estado cambia únicamente cuando ocurre un evento específico, como la llegada de un cliente, la finalización de un servicio o la reposición de un inventario. Su principal ventaja consiste en permitir el estudio del comportamiento de sistemas complejos sin necesidad de intervenir sobre el sistema real, facilitando el análisis de distintas configuraciones y la evaluación de su desempeño.

En este trabajo se estudian dos modelos utilizados en investigación operativa y simulación. El primero corresponde a un sistema de colas MM1, caracterizado por un único servidor, llegadas de clientes según un proceso de Poisson y tiempos de servicio con distribución exponencial. Sobre este modelo se analizan medidas de rendimiento, entre ellas el número promedio de clientes en el sistema y en cola, los tiempos promedio de espera y permanencia, la utilización del servidor, la distribución del número de clientes en cola y la probabilidad de denegación de servicio para distintos tamaños máximos de cola. Asimismo, se evalúa el efecto de modificar la tasa de arribos respecto de la tasa de servicio.

El segundo modelo corresponde a un sistema de inventario, cuyo objetivo es analizar el equilibrio entre los costos asociados a la gestión del stock. Para ello se consideran el costo de ordenar, el costo de mantenimiento, el costo por faltantes y el costo total, estudiando el comportamiento del sistema bajo diferentes configuraciones de parámetros.

Para ambos modelos se desarrollan implementaciones en Python y en AnyLogic, realizando un mínimo de treinta corridas independientes para cada experimento con el propósito de reducir la variabilidad inherente a la simulación y obtener estimaciones confiables de las medidas de rendimiento.

Finalmente, los resultados experimentales se comparan con los valores teóricos correspondientes a cada modelo, permitiendo validar las implementaciones desarrolladas y analizar las diferencias entre los resultados analíticos y los obtenidos mediante simulación.

2. Modelo M/M/1

2.1. Marco teórico

Los sistemas de colas constituyen una de las herramientas más utilizadas en investigación operativa para modelar situaciones en las que un conjunto de clientes, personas o entidades solicita un servicio proporcionado por uno o más servidores. Estos modelos permiten analizar el comportamiento del sistema y evaluar indicadores de desempeño como los tiempos de espera, la longitud de las colas y la utilización de los recursos.

En este trabajo se estudia un sistema de colas M/M/1, uno de los modelos más simples y ampliamente utilizados en la teoría de colas. La notación M/M/1 indica que los tiempos entre llegadas siguen una distribución exponencial (equivalente a un proceso de Poisson), los tiempos de servicio también siguen una distribución exponencial y el sistema dispone de un único servidor.

El modelo M/M/1 se basa en los siguientes supuestos:

- Las llegadas de los clientes siguen un proceso de Poisson con tasa de arribo λ.
- Los tiempos de servicio siguen una distribución exponencial con tasa de servicio μ.
- Existe un único servidor.
- Los clientes son atendidos según la disciplina FIFO (First In, First Out).
- La población potencial de clientes es infinita.
- Inicialmente se considera una cola de capacidad infinita y posteriormente se analiza el caso de capacidad finita.
- Las llegadas y los tiempos de servicio son independientes entre sí.

El comportamiento del sistema depende principalmente de la relación entre la tasa de llegada y la tasa de servicio, definida mediante el factor de utilización:

$\rho = \frac{\lambda}{\mu}$

Este parámetro representa la fracción del tiempo durante la cual el servidor permanece ocupado. Para que el sistema alcance un estado estable debe cumplirse que:

$\rho < 1$

Cuando la tasa de llegada supera a la tasa de servicio ($\rho > 1$), la longitud de la cola tiende a crecer indefinidamente y el sistema deja de ser estable.

Las principales medidas de rendimiento analizadas en un sistema M/M/1 son las siguientes:

- Número promedio de clientes en el sistema (L).
- Número promedio de clientes en cola (L_q).
- Tiempo promedio de permanencia en el sistema (W).
- Tiempo promedio de espera en cola (W_q).
- Utilización del servidor (ρ).
- Probabilidad de encontrar n clientes en el sistema.
- Probabilidad de denegación de servicio cuando la capacidad de la cola es finita.

Para el caso de una cola con capacidad infinita y condición de estabilidad ($\rho < 1$), las expresiones teóricas son:

L=$\rho\frac{}{1-\rho}$

$\mathrm{L}_q = \frac{\rho^2}{1-\rho}$

W=1$\frac{}{\mu-\lambda}$

$\mathrm{W}_q = \frac{\rho}{\mu-\lambda}$

Estas expresiones también satisfacen la Ley de Little:

L=λW

$L_q = \lambda W_q$

La probabilidad de encontrar exactamente n clientes en el sistema está dada por:

P(n)=(1-ρ)ρ^n

Esta distribución permite conocer la probabilidad de que el sistema tenga una determinada cantidad de clientes en un instante cualquiera.

Además del caso de capacidad infinita, en este trabajo se estudia un sistema con capacidad limitada. En este escenario existe un número máximo de clientes permitidos en la cola y, cuando dicha capacidad se encuentra completa, los nuevos clientes que arriban no pueden ingresar al sistema y son rechazados. La proporción de clientes rechazados constituye la probabilidad de denegación de servicio, la cual representa una medida importante del desempeño cuando existen restricciones de capacidad.

Cuando la capacidad del sistema es finita (modelo M/M/1/K, con K la capacidad total incluyendo al cliente en servicio), la probabilidad de encontrar n clientes en el sistema es:

$$\text{P(n)}=\begin{cases} \dfrac{(1-\rho)\,\rho^n}{1-\rho^{K+1}} & \rho \neq 1 \\ \dfrac{1}{K+1} & \rho = 1 \end{cases} \qquad \text{n=0,1,...,K}$$

A diferencia del caso de capacidad infinita, este modelo es estable para cualquier valor de ρ, incluyendo $\rho \geq 1$, ya que la cola no puede crecer indefinidamente. La probabilidad de denegación de servicio (bloqueo) es la probabilidad de encontrar el sistema completo:

$P_{bloqueo} = P(K)$

Debido al bloqueo, la tasa de arribos efectiva que ingresa al sistema es menor a λ:

$\lambda_{ef} = \lambda\,(1 - P_{bloqueo})$

y las medidas de rendimiento se recalculan usando λ_{ef} en lugar de λ:

L=$\sum_{n=0}^{K} n\,P(n)$ $\qquad W = \frac{L}{\lambda_{ef}}$ $\qquad L_q = L - (1 - P(0))$ $\qquad W_q = \frac{L_q}{\lambda_{ef}}$

Por otro lado, la distribución del número de clientes **en cola** (sin contar al que está siendo atendido, N_q) se obtiene a partir de $P(n)$ notando que $N_q = 0$ tanto si el sistema está vacío como si hay exactamente un cliente en servicio:

P($N_q = 0$) $= P(0) + P(1) = 1 - \rho^2$

P($N_q = k$) $= P(k+1) = (1-\rho)\,\rho^{k+1}, \qquad k \geq 1$

Esta distribución solo está definida para $\rho < 1$ (condición de estabilidad); para $\rho \geq 1$ el sistema con cola infinita no alcanza estado estable y estos valores no se calculan.

2.2. Metodología

El modelo M/M/1 fue implementado mediante simulación por eventos discretos. En este tipo de simulación el estado del sistema únicamente cambia cuando ocurre un evento, evitando realizar cálculos innecesarios entre eventos consecutivos y permitiendo representar el comportamiento del sistema de manera eficiente.

Para este modelo se consideran dos tipos de eventos: la llegada de un cliente al sistema y la finalización de su servicio. Cada evento provoca una actualización del estado del sistema, modificando la cantidad de clientes presentes, el estado del servidor y las variables necesarias para el cálculo de las medidas de rendimiento.

Con el objetivo de validar los resultados obtenidos, el modelo fue implementado utilizando dos herramientas diferentes: un programa desarrollado en Python y un modelo equivalente construido en AnyLogic. Los resultados de ambas implementaciones se comparan posteriormente con los valores teóricos obtenidos mediante las expresiones de la teoría de colas.

Durante los experimentos se mantiene constante la tasa de servicio y se analiza el comportamiento del sistema variando la tasa de arribos. Para ello se consideran cinco escenarios, correspondientes al 25 %, 50 %, 75 %, 100 % y 125 % de la tasa de servicio. De esta manera es posible evaluar cómo cambia el desempeño del sistema a medida que aumenta la carga de trabajo.

Asimismo, para el estudio de la cola finita se consideran diferentes capacidades máximas de espera, correspondientes a 0, 2, 5, 10 y 50 clientes. En cada caso se calcula la probabilidad de denegación de servicio y se analiza el impacto de la capacidad disponible sobre el desempeño general del sistema.

Con el fin de reducir la variabilidad inherente a los procesos estocásticos, cada experimento se ejecuta un mínimo de treinta corridas independientes. Las medidas de rendimiento se obtienen a partir del promedio de dichas corridas, permitiendo obtener estimaciones estadísticamente más representativas.

Durante la simulación se registran las principales variables de interés: el número promedio de clientes en el sistema, el número promedio de clientes en cola, el tiempo promedio de permanencia en el sistema, el tiempo promedio de espera en cola, la utilización del servidor, la distribución del número de clientes presentes y la probabilidad de denegación de servicio para cada una de las capacidades de cola analizadas. Estos resultados serán posteriormente comparados con los valores teóricos y con los obtenidos mediante la implementación en AnyLogic.

2.3. Resultados: cola infinita

La Tabla 1 resume las medidas de rendimiento obtenidas mediante simulación (promedio de 30 corridas, con su intervalo de confianza del 95 %) y su comparación con los valores teóricos, para cada uno de los cinco escenarios de carga considerados.

Cuadro 1: Medidas de rendimiento M/M/1 con cola infinita, variando λ/μ.

λ/μ	L (sim.)	L (teo.)	W (sim.)	W (teo.)	ρ (sim.)
0.25	0.332	0.333	1.332	1.333	0.248
0.50	0.996	1.000	1.994	2.000	0.498
0.75	3.002	3.000	3.997	4.000	0.750
1.00	95.617	–	95.585	–	0.992
1.25	2509.024	–	2006.229	–	1.000

Para $\rho \geq 1$ el sistema con cola infinita es inestable: la longitud de la cola crece sin cota y los valores teóricos de L, L_q, W y W_q divergen. Esto se refleja en la simulación como una tendencia creciente sin estabilizarse, en lugar de converger a un valor finito (ver Figura 1).

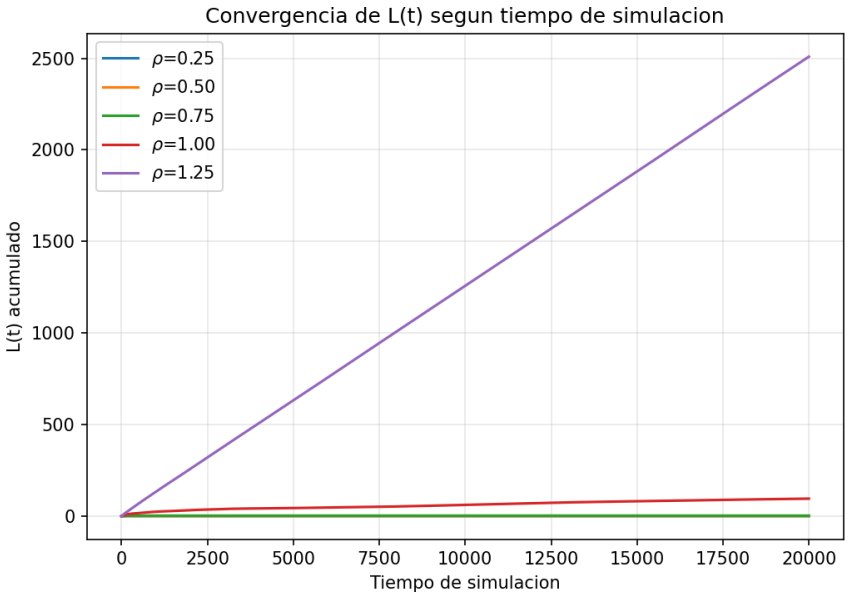
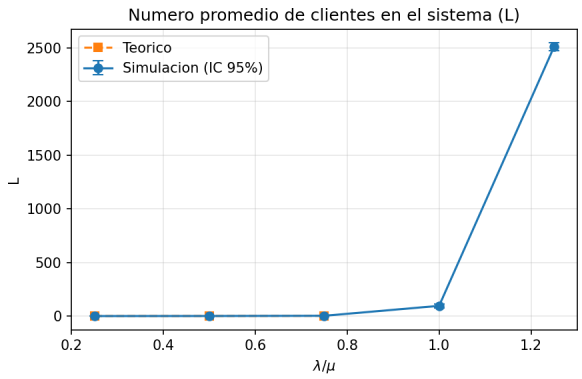
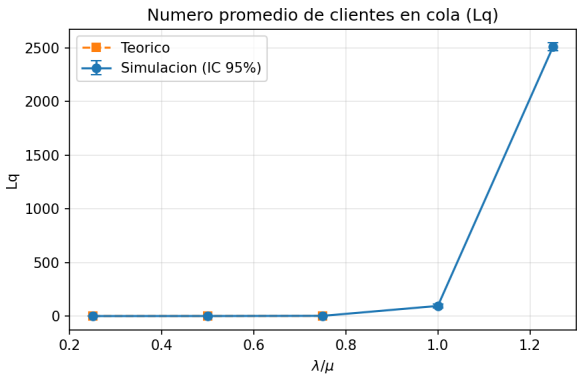


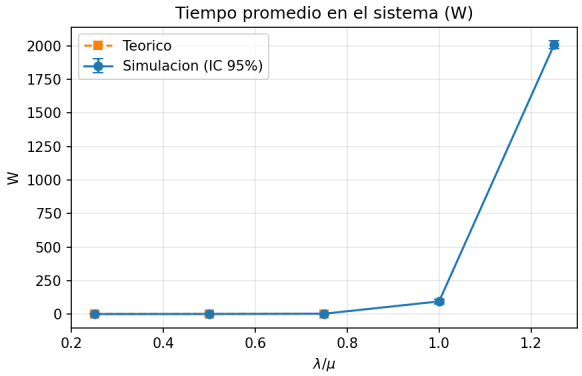
Figura 1: Evolución del número promedio de clientes en el sistema $L(t)$ a medida que avanza el tiempo de simulación, para cada valor de ρ. Se observa la convergencia a un valor estable cuando $\rho < 1$, y el crecimiento sin cota cuando $\rho \geq 1$.



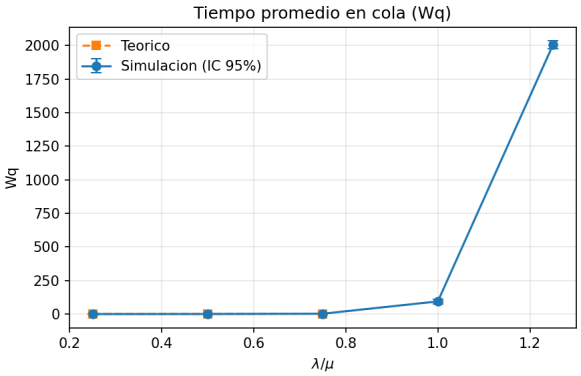
(a) Número promedio de clientes en el sistema



(b) Número promedio de clientes en cola



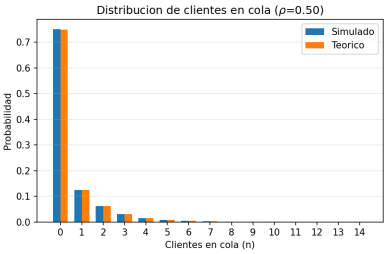
(c) Tiempo promedio en el sistema



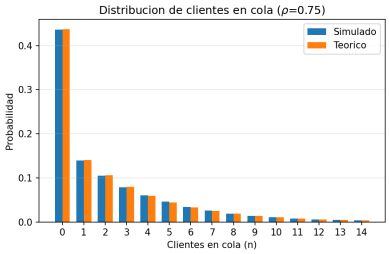
(d) Tiempo promedio en cola

Figura 2: Medidas de rendimiento en función de λ/μ. Los puntos representan el promedio simulado con su intervalo de confianza del 95 %, y la línea punteada el valor teórico.

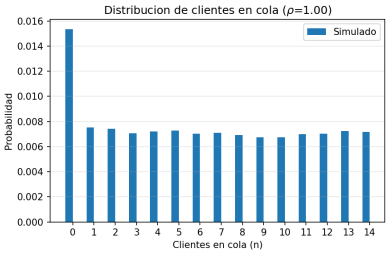
Como se observa en la Figura 2, los valores simulados se ajustan adecuadamente a los valores teóricos para $\rho < 1$, con diferencias dentro del intervalo de confianza. A medida que ρ se acerca a 1, tanto L como W crecen de forma no lineal, lo cual es consistente con el factor $1/(1-\rho)$ presente en las fórmulas teóricas.



(a) $\rho = 0{,}50$



(b) $\rho = 0{,}75$



(c) $\rho = 1{,}00$

Figura 3: Distribución del número de clientes en cola, simulada vs. teórica, para distintos valores de ρ. Para $\rho = 1$ el modelo teórico no está definido (sistema inestable), por lo que la comparación pierde sentido.

La distribución de clientes en cola muestra que, incluso con $\rho = 0{,}75$, la probabilidad de encontrar la cola vacía sigue siendo la más alta, pero la cola de la distribución (colas largas) se vuelve considerablemente más pesada a medida que ρ aumenta, anticipando la inestabilidad que se observa en $\rho = 1$.

2.4. Resultados: cola finita

La Tabla 2 y la Figura 4 muestran la probabilidad de denegación de servicio obtenida para cada combinación de tasa de arribo y tamaño de cola (0, 2, 5, 10 y 50 posiciones de espera).

Cuadro 2: Probabilidad de denegación de servicio para distintos tamaños de cola.

λ/μ	Tamaño de cola	$P_{bloqueo}$ (sim.)	$P_{bloqueo}$ (teo.)
0.25	0	0.1992	0.2000
0.25	2	0.0115	0.0118
0.25	5	0.0002	0.0002
0.25	10	0.0000	0.0000
0.25	50	0.0000	0.0000
0.50	0	0.3338	0.3333
0.50	2	0.0669	0.0667
0.50	5	0.0078	0.0079
0.50	10	0.0002	0.0002
0.50	50	0.0000	0.0000
0.75	0	0.4290	0.4286
0.75	2	0.1555	0.1543
0.75	5	0.0517	0.0513
0.75	10	0.0107	0.0109
0.75	50	0.0000	0.0000
1.00	0	0.5003	0.5000
1.00	2	0.2505	0.2500
1.00	5	0.1416	0.1429
1.00	10	0.0836	0.0833
1.00	50	0.0189	0.0192
1.25	0	0.5560	0.5556
1.25	2	0.3385	0.3388
1.25	5	0.2535	0.2531
1.25	10	0.2125	0.2148
1.25	50	0.1984	0.2000

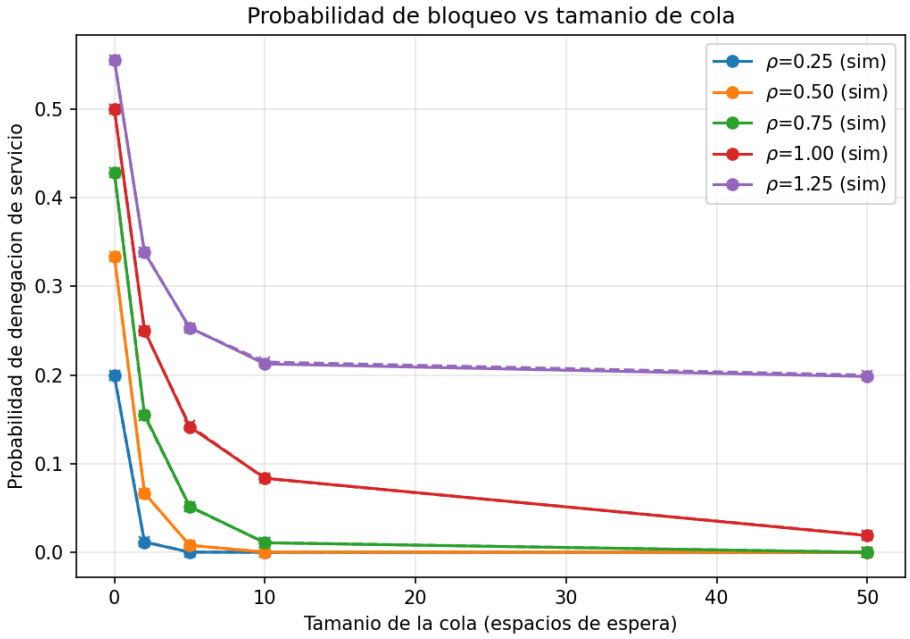


Figura 4: Probabilidad de denegación de servicio en función del tamaño de la cola, para cada tasa de arribo. Los puntos son los valores simulados y las líneas punteadas los valores teóricos de M/M/1/K.

Se observa que, para tasas de arribo bajas ($\lambda/\mu = 0{,}25$), una cola de tamaño moderado (5 a 10 posiciones) ya reduce la probabilidad de bloqueo a valores prácticamente nulos. En cambio, para $\lambda/\mu = 1{,}25$ (sistema sobrecargado), incluso una cola de 50 posiciones mantiene una probabilidad de bloqueo cercana al 20 %, dado que el sistema recibe más clientes de los que puede procesar en promedio. Este resultado ilustra que, ante una sobrecarga estructural del servidor, aumentar el tamaño de la cola no es una solución suficiente: es necesario aumentar la tasa de servicio o reducir la tasa de arribos.

3. Modelo de Inventario

3.1. Marco teórico

El problema de gestión de inventario consiste en determinar cuándo y cuánto reponer de un artículo, de forma de equilibrar tres costos en conflicto: el costo de emitir órdenes de compra, el costo de mantener stock en depósito y el costo de no poder satisfacer la demanda por falta de stock.

En este trabajo se adopta una política de revisión periódica (s, S): en cada período se observa la posición de inventario (stock disponible más lo pedido en camino, menos los pedidos pendientes de entregar) y, si esta cae por debajo del punto de pedido s, se emite una orden de reposición hasta alcanzar el nivel S. La orden demora un tiempo de entrega (*lead time*) fijo antes de estar disponible.

Los costos considerados son:

- **Costo de orden**: costo fijo K por cada orden emitida, independiente de la cantidad pedida.
- **Costo de mantenimiento**: costo h por unidad de producto en stock y por período.
- **Costo de faltante**: costo p por unidad de demanda no satisfecha (backorder) y por período que permanece pendiente.
- **Costo total**: suma de los tres anteriores.

Como valor teórico de referencia se utiliza el modelo determinista de lote económico (EOQ) con faltantes planificados. Este modelo asume una demanda constante y conocida D (unidades por período), y determina el tamaño de lote Q y el nivel máximo de inventario S^* que minimizan el costo total por unidad de tiempo:

$$\mathrm{Q}^* = \sqrt{\frac{2DK}{h} \cdot \frac{h+p}{p}}$$

$$\mathrm{S}^* = Q^* \cdot \frac{p}{h+p}$$

El faltante máximo permitido resulta $Q^* - S^*$, y el costo total óptimo por unidad de tiempo es:

$$\mathrm{CT}^* = \sqrt{2DKhp/(h+p)}$$

Dado que este modelo asume demanda determinista, se lo utiliza como una **cota de referencia**: el sistema estocástico simulado necesariamente incurre en un costo mayor o igual, ya que debe mantener stock de seguridad adicional para cubrirse frente a la variabilidad de la demanda durante el lead time.

3.2. Metodología

Se simula un sistema de inventario mediante revisión periódica, con demanda diaria aleatoria según una distribución de Poisson (por su adecuación para modelar la llegada de pedidos de clientes minoristas) y lead time fijo. Los parámetros elegidos, junto con su justificación, son los siguientes:

- Demanda media $\lambda_D = 5$ unidades por día: representa una demanda minorista moderada.
- Lead time de 3 días: tiempo de reposición típico de un proveedor local.
- Costo de orden $K = 50$: agrupa gastos administrativos y de transporte por pedido.
- Costo de mantenimiento $h = 1$ por unidad y por día: representa el costo de oportunidad del capital inmovilizado y el espacio de depósito.
- Costo de faltante $p = 5$ por unidad y por día en backorder: se fija en 5 veces el costo de mantenimiento para reflejar que la falta de stock (clientes disconformes, pérdida de ventas) resulta considerablemente más costosa que mantener inventario de más.

Los valores de (s, S) no se fijan arbitrariamente: se calculan combinando el lote económico Q^* (como tamaño de lote de reposición) con un stock de seguridad igual a $z \cdot \sigma_{LT}$, donde $\sigma_{LT} = \sqrt{\lambda_D \cdot LT}$ es el desvío estándar de la demanda durante el lead time (por tratarse de una suma de variables Poisson) y $z = 1{,}65$ corresponde a un nivel de servicio del 95 %. De esta forma:

$$\mathrm{s} = \lambda_D \cdot LT + z \cdot \sigma_{LT} \qquad S = s + Q^*$$

A partir de esta política de referencia se realiza además un barrido de distintas combinaciones de (s, S), para comparar el desempeño de diferentes políticas y estudiar la sensibilidad del costo total frente a cada parámetro. Cada configuración se evalúa mediante 30 corridas independientes de 2000 períodos cada una, promediando los resultados.

3.3. Resultados

La Tabla 3 muestra los costos obtenidos para la política (s, S) sugerida, comparados contra el costo teórico del modelo EOQ con faltantes.

Cuadro 3: Costos por período para la política (s, S) propuesta, comparados con el valor teórico EOQ.

Componente de costo	Simulado	IC95	Teórico (EOQ)
Costo de orden	9.068	0.035	10.206
Costo de mantenimiento	20.207	0.047	8.505
Costo de faltante	0.031	0.005	1.701
Costo total	29.306	0.032	20.412

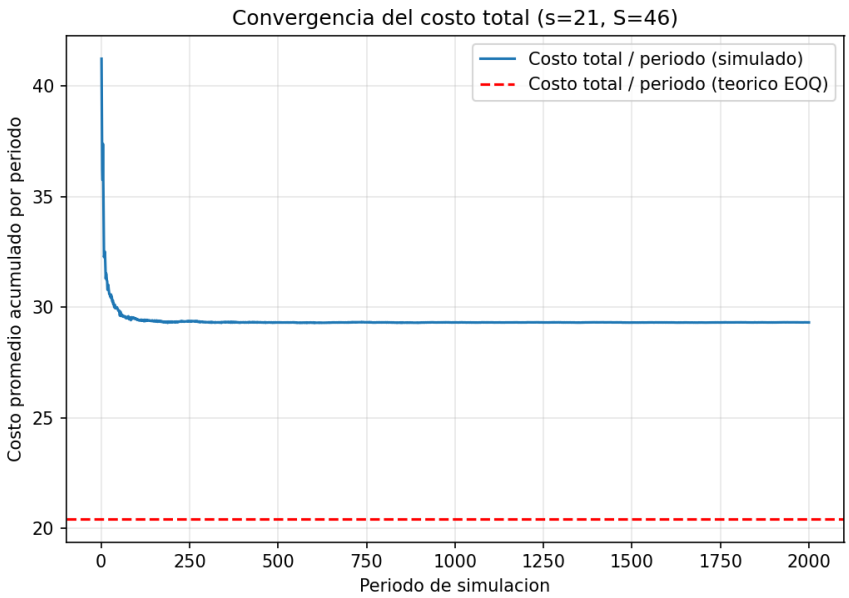
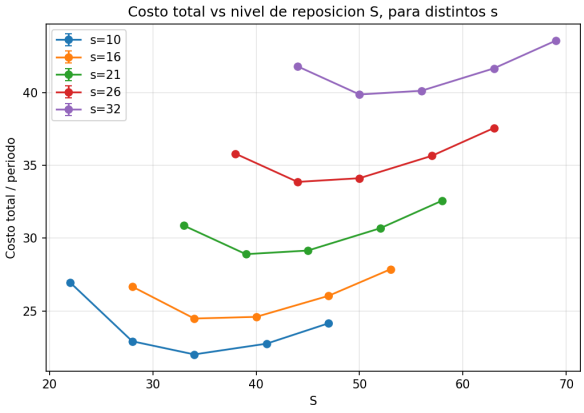


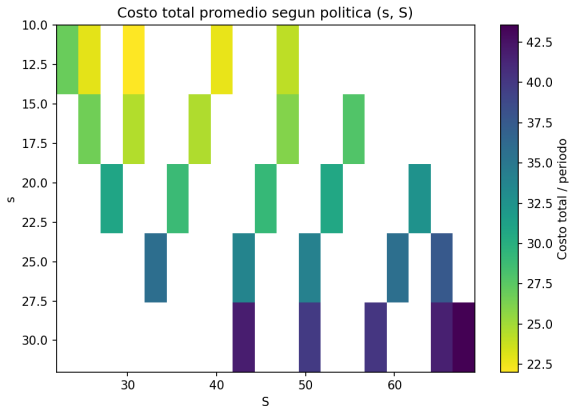
Figura 5: Evolución del costo total promedio por período a medida que avanza la simulación, comparado con el valor teórico EOQ (línea punteada).

Como era esperable, el costo de mantenimiento simulado resulta considerablemente mayor al teórico, mientras que el costo de faltante simulado es casi nulo. Esto se debe a que la política (s, S) propuesta incorpora un stock de seguridad para alcanzar un 95 % de nivel de servicio frente a la demanda variable, lo cual implica mantener más inventario del estrictamente necesario en el caso determinista, a cambio de casi no incurrir en faltantes.

Para explorar este *trade-off*, se realizó un barrido de distintas combinaciones de (s, S), cuyos resultados se resumen en la Figura 6.



(a) Costo total vs. nivel de reposición S, para distintos valores de s



(b) Mapa de calor del costo total según (s, S)

Figura 6: Sensibilidad del costo total frente a distintas políticas (s, S).

El barrido muestra que existe una combinación de (s, S) que minimiza el costo total simulado, más cercana al óptimo teórico que la política inicialmente propuesta con un nivel de servicio del 95 %. Esto evidencia que, si bien un nivel de servicio alto reduce el riesgo de faltantes, tiene un costo asociado en términos de inventario mantenido, y la política óptima depende fuertemente de la relación entre h y p elegida.

4. Comparación entre las fuentes de datos

Para validar los modelos desarrollados, se compararon los resultados obtenidos a partir de tres fuentes: el valor teórico esperado, la implementación en Python y una implementación equivalente en AnyLogic, para el escenario base $\lambda/\mu = 0{,}8$.

Cuadro 4: Comparación de resultados M/M/1 ($\lambda = 0{,}8$, $\mu = 1{,}0$) entre las tres fuentes, cada una promediada sobre 30 corridas.

Medida	Teórico	Python	AnyLogic
L	4.000	3.930	4.029
L_q	3.200	3.131	3.227
W	5.000	4.911	5.036
W_q	4.000	3.913	4.034
ρ	0.800	0.799	0.801

Las tres fuentes coinciden con una diferencia menor al 3 % en todas las medidas, lo cual valida tanto la implementación en Python como la construida en AnyLogic. La pequeña dispersión observada es consistente con la variabilidad muestral esperada al promediar 30 corridas de un proceso estocástico, y no evidencia ningún sesgo sistemático entre plataformas.

Cuadro 5: Comparación de costos de inventario entre las tres fuentes (política $s = 21$, $S = 46$).

Componente	Teórico (EOQ)	Python	AnyLogic
Costo de orden	10.206	9.068	8.833
Costo de mantenimiento	8.505	20.207	20.658
Costo de faltante	1.701	0.031	0.023
Costo total	20.412	29.306	29.514

Las columnas de Python y AnyLogic coinciden entre sí con una diferencia menor al 3 % en cada componente, lo cual valida ambas implementaciones de la política (s, S). Como ya se discutió, ambas superan al valor teórico del modelo EOQ en el costo de mantenimiento, dado que este último no contempla el stock de seguridad necesario para cubrir la variabilidad de la demanda durante el lead time.

5. Conclusiones

Los resultados obtenidos mediante simulación por eventos discretos en Python se ajustan adecuadamente a los valores teóricos esperados, tanto para el modelo de colas M/M/1 como para el modelo de inventario, validando las implementaciones desarrolladas.

En el caso del modelo M/M/1, se verificó que las medidas de rendimiento crecen de forma no lineal a medida que la utilización del servidor se acerca a 1, y que para $\rho \geq 1$ el sistema con cola infinita resulta inestable, tal como predice la teoría. La incorporación de una cola finita permite acotar esta inestabilidad, a costa de una probabilidad de denegación de servicio que depende fuertemente de la relación entre la tasa de arribo y la de servicio: un aumento en el tamaño de la cola solo resulta efectivo cuando el sistema no está estructuralmente sobrecargado.

En el modelo de inventario, se observó el clásico *trade-off* entre el costo de mantenimiento y el costo de faltante: una política orientada a un alto nivel de servicio reduce casi a cero los faltantes, pero incrementa el costo de mantenimiento por encima del óptimo determinista. El barrido de políticas (s, S) permitió identificar una combinación de parámetros con menor costo total, más cercana al valor teórico del modelo EOQ con faltantes.

La comparación entre las tres fuentes —teórico, Python y AnyLogic— fue realizada para ambos modelos, mostrando en todos los casos una coincidencia adecuada entre las dos implementaciones de simulación, y una diferencia esperable frente a los modelos teóricos de referencia (inestabilidad para $\rho \geq 1$ en M/M/1, y la ausencia de stock de seguridad en el modelo EOQ determinista). Esto valida tanto los programas desarrollados en Python como los modelos equivalentes construidos en AnyLogic como herramientas confiables para el estudio de ambos sistemas.

Referencias

[1] Averill M. Law. Simulation Modeling and Analysis.

[2] Anylogic Team. The Art of Process Centric Modeling.

[3] Sheldon M. Ross. Simulación